UNIVERSIDAD DE SANTIAGO DE CHILE

FACULTAD DE INGENIERÍA

Departamento de Ingeniería Industrial



PROYECTO INTEGRADOR: REGRESIÓN

CASO 1

CONSUMO DE COMBUSTIBLE DEL CPS TRITÓN

Integrantes del equipo

Sylvia Montanares

Vladimir Painiqueo

Isidora Rioseco

Hernán Silva

Germán Troncoso

PROFESOR: Luis Rojo-González, Ph.D.

ASIGNATURA: Estadística Aplicada

SANTIAGO - CHILE

2026

Índice

Resumen ejecutivo..... 3
1. Problema, datos y disponibilidad temporal..... 3
2. Relaciones e inferencia..... 3
3. Validación y preparación..... 4
4. Modelos..... 4
5. Comparación, test y subgrupos..... 5
6. Interpretación, límites y recomendación..... 6
Referencias..... 8
Anexos..... 8
A. Diccionario de variables..... 8
B. Reproducibilidad y declaración de IA..... 9
C. Resultados completos de validación e hiperparámetros..... 10
D. Figuras de apoyo..... 11

Resumen ejecutivo

Se predice el consumo instantáneo de combustible (kg/s) del buque CPS Tritón a partir de su velocidad y de las condiciones del clima y el mar, para planificar el combustible a cargar en cada viaje. Se compararon doce modelos frente a un baseline (promedio por zona), con partición temporal y validación cruzada por bloques. Se seleccionó Splines/GAM: el Stacking tuvo un error levemente menor, pero hubo empate estadístico y el GAM es más simple. En test, evaluado una sola vez, el GAM alcanzó un RMSE de 0.0254 kg/s, 18.6 % menos que el baseline, aunque en maniobras (1 a 6 m/s) la mejora fue de solo 5.4 %. Solo es válido para este buque, ruta y época.

1. Problema, datos y disponibilidad temporal

La optimización operativa en el transporte marino requiere minimizar el gasto de combustible y emisiones de contaminantes. La decisión que apoya el modelo es cuánto combustible cargar para cada viaje, dada la velocidad planificada y las condiciones meteorológicas y del océano esperadas; además, permite detectar consumos anómalos al comparar el consumo real con el esperado. La unidad de análisis corresponde al estado operativo del buque “CPS Tritón” y su entorno en cada intervalo de 5 minutos.

La variable respuesta a estimar es la tasa de consumo instantáneo de combustible. Además, el enfoque analítico que se tiene, está basado en una regresión multivariada no como un pronóstico clásico de series de tiempo, es decir, el sistema no utiliza el consumo histórico de horas o días previos para proyectar el consumo futuro. En su lugar, el modelo captura la tasa de consumo de combustible en un instante específico basándose en condiciones operacionales y ambientales que el buque enfrenta en ese mismo instante. La población de interés es la operación del CPS Tritón en condiciones similares a las observadas, incluyendo detenciones, maniobras y navegación en crucero; cerca del 26% de las filas de entrenamiento corresponde a velocidad casi nula (<1 m/s), y la zona "intermedia" (1 a 6 m/s), que corresponde a maniobras, se analiza como subgrupo crítico.

Los datos provienen de FuelCast, subconjunto cps_triton (Hugging Face) [1, 2], con licencia CC BY-NC-ND 4.0. Tienen 25351 registros de 5 minutos y 62 columnas. Se eliminaron 43 filas con faltantes (0.2 %), sin imputar: se concentran en cortes breves de los sensores y de la fuente meteorológica, sin relación aparente con el consumo, por lo tanto, se asume que faltan al azar y es poco probable que eliminarlas sesgue los resultados. Se detectaron 60 consumos atípicos según la regla del rango intercuartílico; se mantienen porque corresponden a operación real del buque. Al decidir se conocen la velocidad planificada, la profundidad y el clima y el mar. Se excluyen *Consumer_** y *Propeller_** (consecuencia del consumo: fuga de información), *Ship_SpeedThroughWater* (constante), las irradiancias (valores imposibles) y *Ship_Bearing* (redundante: el ángulo relativo se calcula con *Ship_Heading*). El clima es histórico (Open-Meteo [3]), con resolución horaria interpolada a 5 minutos; no son pronósticos, por lo que al planificar habría que reemplazarlos por pronósticos, con más error.

2. Relaciones e inferencia

Existe una relación no lineal entre el consumo y la velocidad del buque: el consumo aumenta con la velocidad, pero no de forma proporcional. Para analizar las demás variables se ajustó un modelo OLS con variables estandarizadas, evaluando la significancia estadística ($p < 0.05$) y la relevancia práctica, definida como un efecto mayor o igual al 1 % del consumo medio por cada desviación estándar.

Las variables significativas y relevantes son el viento de frente, la velocidad del viento, la temperatura, la corriente de frente, la altura de la ola, la ola de frente y el período de la ola. Por ejemplo, una desviación estándar más de viento de frente se asocia a +0.0064 kg/s (IC 95 %: 0.0060 a 0.0069; 3.6 % del consumo medio). La velocidad del buque domina (correlación de 0.88 con el consumo). La profundidad, la ola y la corriente laterales son significativas ($p < 0.01$) por el gran tamaño de la muestra, pero no relevantes (efecto menor al 1 % del consumo medio).

Por último, los residuos del OLS mostraron varianza no constante (dos grupos), no normalidad y autocorrelación fuerte (0.69 entre filas consecutivas; Figura A1 en el Anexo D). Por eso los p-valores y los intervalos del OLS son optimistas y se usan solo como guía, y la comparación de modelos se apoya en el error fuera de muestra (validación) y en intervalos bootstrap por bloques.

3. Validación y preparación

Para respetar la naturaleza de serie de tiempo y evitar sobreestimación por autocorrelación, los datos se dividieron cronológicamente en: Entrenamiento (Train), el cual corresponde al 60% inicial de los datos, luego Validación (Valid), que corresponde al 20% intermedio y por último Prueba (Test) que corresponde al 20% final. Se insertó un margen de 60 filas (5 horas; hueco o Gap) eliminadas entre cada partición. Quedaron 15184 filas de entrenamiento, 5002 de validación y 5002 de prueba. El hueco se justifica porque las filas vecinas son casi copias: la correlación del consumo con la fila anterior es 0.96 y la autocorrelación tarda ~55 filas en desaparecer. Una partición al azar habría puesto copias del entrenamiento en el test e inflado el desempeño.

Para elegir los hiperparámetros se usó validación cruzada en 5 bloques de tiempo contiguos dentro del entrenamiento, respetando el mismo hueco. Las transformaciones no usan información del test: las direcciones del viento, las olas y la corriente se convierten en coseno y seno respecto a la proa del buque (cálculo sin parámetros aprendidos), la estandarización usa solo el entrenamiento y se eliminan las 43 filas con faltantes sin imputar. La semilla global es 123 y el script se detiene automáticamente si hay columnas *Consumer_** o *Propeller_** como predictoras, o si los bloques se solapan o no respetan el orden del tiempo. El test se evaluó una sola vez, con el modelo fijado antes de verlo.

4. Modelos

Se evaluaron y afinaron sistemáticamente doce modelos. Baseline, el cual tuvo un promedio del consumo segmentado por 3 zonas de velocidad, casi detenido (con una velocidad <1m/s), intermedia (con velocidad de 1 a 6 m/s) y velocidad crucero (con una velocidad >6m/s). Otro enfoque fue la Referencia Cúbica y OLS con clima, la cual es una regresión polinomial sobre velocidad y modelo OLS con predictores meteorológicos completados. Los modelos regularizados (Ridge,Lasso, Elastic-net), los cuales fueron evaluados vía glmnet seleccionando la penalización con la regla lambda.1se derivada de la CV por bloques. Splines/GAM, el cual fue ajustado mediante mgcv::bam, optimizando los grados de libertad (k_vel y k_otras) para capturar curvas hidrodinámicas suaves; los valores elegidos fueron k_vel = 80 y k_otras = 3.

Además, se ajustaron un Árbol de regresión (rpart, con profundidad máxima 6), un Random Forest (ranger, con 300 árboles, mtry = 9 y tamaño mínimo de nodo 500) y Boosting (gbm, con 400 árboles, profundidad 6 y tasa de aprendizaje 0.02). Por último, se probaron dos combinaciones de modelos: el Averaging, que promedia OLS, GAM, Random Forest y Boosting, y el Stacking, que los combina con pesos no negativos (Boosting 0.65, Random Forest 0.22, OLS 0.07 y GAM 0.06) calculados con predicciones fuera de muestra del entrenamiento. Todos los hiperparámetros se eligieron con

validación cruzada por bloques de tiempo dentro del entrenamiento, y el modelo final con la validación y el principio de parsimonia.

5. Comparación, test y subgrupos

La comparación se centró en el RMSE general (todo el viaje) y en el RMSE del subgrupo de 1 a 6 m/s, un rango crítico porque corresponde a maniobras y transiciones, y es donde el baseline comete su mayor error (0.0506 en validación).

En validación, el Stacking tuvo el menor error (RMSE 0.0247), pero el GAM (0.0256) empata con él: la diferencia de MAE es de 0.0005 kg/s y su IC 95 % (−0.0002 a 0.0013) incluye el 0. Por parsimonia se eligió el GAM, más simple y fácil de interpretar. Además, mejora al baseline en 0.0059 kg/s de MAE (IC 95 %: 0.0045 a 0.0075) y gana en los 5 bloques de tiempo. Como un IC que incluye el 0 no prueba equivalencia, se verificó además que el peor caso (0.0013 kg/s de MAE adicional) es menor que el umbral de relevancia del proyecto (1 % del consumo medio, 0.0018 kg/s), por lo que la diferencia no es relevante en la práctica. La Tabla 1 resume la validación por familia de modelos y la tabla completa de los 12 modelos está en el Anexo C (Tabla 4).

Tabla 1: Resultados de validación por familia (RMSE y MAE en kg/s; subgrupo: velocidad de 1 a 6 m/s). En las familias con varios modelos se muestra el mejor en validación.

Modelo	**Familia**	**RMSE general**	**MAE**	**R^2**	**RMSE subgrupo**	**vs baseline**
Baseline (promedio por zona)	—	0.0329	0.0250	0.765	0.0506	n/a
OLS con clima	Lineal	0.0271	0.0203	0.840	0.0421	17.6 % menos RMSE
Ridge / Lasso / EN (mejor: Lasso)	Regularizado	0.0285	0.0213	0.824	0.0450	13.4 % menos RMSE
Splines / GAM (modelo final)	Flexible	0.0256	0.0191	0.858	0.0399	22.2 % menos RMSE
Random Forest	Ensemble	0.0252	0.0189	0.863	0.0398	23.6 % menos RMSE
Boosting	Ensemble	0.0248	0.0186	0.866	0.0388	24.6 % menos RMSE
Stacking / averaging (mejor: Stacking)	Ensemble	0.0247	0.0185	0.868	0.0387	25.0 % menos RMSE

En test (Tabla 2), el GAM mantuvo su RMSE general (0.0254, 18.6 % menos que el baseline), sin señales de sobreajuste, con una mejora del MAE de 0.0051 kg/s (IC 95 %: 0.0037 a 0.0066). Por zona de velocidad, el RMSE bajó 23 % con el buque casi detenido (1176 filas) y 19 % en crucero (3470 filas); en cambio, en el subgrupo de 1 a 6 m/s la mejora cayó a 5.4 % (21.1 % en validación): es el

punto débil del modelo, aunque con solo 356 filas la cifra es inestable. El intervalo de predicción al 95 %, calibrado en validación por zona (±0.062 kg/s casi detenido, ±0.067 en maniobras y ±0.044 en crucero), cubre el 95.2 % de las observaciones de test.

Tabla 2: Sistema final (Splines/GAM), validación contra test.

Métrica	**Baseline (validación)**	**GAM (validación)**	**Baseline (test)**	**GAM (test)**
RMSE general (kg/s)	0.0329	0.0256	0.0312	0.0254
RMSE subgrupo (kg/s)	0.0506	0.0399	0.0427	0.0404
MAE (kg/s)	0.0250	0.0191	0.0245	0.0194
R^2	0.765	0.858	0.708	0.806
Mejora del RMSE general	—	22.2 %	—	18.6 %
Mejora del RMSE subgrupo	—	21.1 %	—	5.4 %

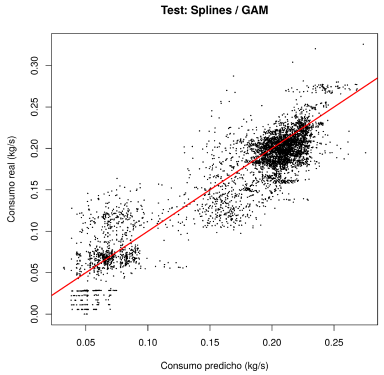


Figura 2. Consumo real contra consumo predicho por el GAM en el conjunto de test.

6. Interpretación, límites y recomendación

El modelo sirve para estimar el consumo del CPS Tritón en condiciones similares a las observadas, pero no para otros buques, rutas o estaciones, y sus relaciones son asociaciones, no causas.

Interpretación sin causalidad: Si el viento o las olas vienen de frente, el consumo es mayor; si la corriente va a favor, es menor. La velocidad domina: en el Random Forest su importancia por permutación es unas 40 veces la de la variable que le sigue. Según el PDP/ICE del GAM (Figura 3), el consumo salta de ~0.08 a ~0.16 kg/s entre 0 y 0.5 m/s, queda casi plano hasta ~5 m/s y sube hasta ~0.25 kg/s a 8 m/s; el viento y las olas lo aumentan de forma casi lineal y leve. Las curvas individuales son casi paralelas al promedio (efecto aditivo) y se separan en dos grupos que corresponden a los dos regímenes de operación.

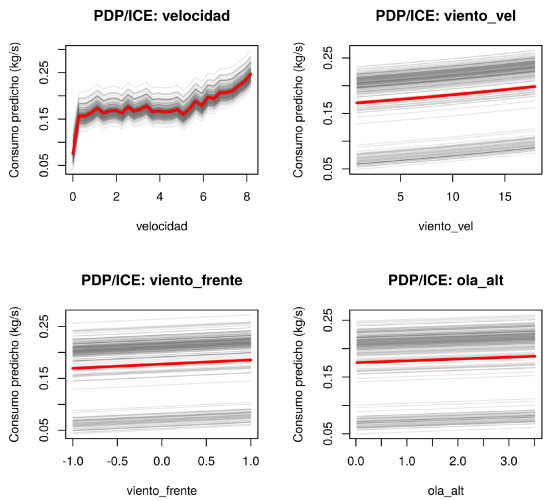


Figura 3. PDP (línea roja) e ICE (líneas grises) del GAM para la velocidad, la velocidad del viento, el viento de frente y la altura de ola.

Límites:

- Extrapolación: los datos son ~3 meses de temporada fría (temperatura media de 3 °C), una ruta y un buque, por lo que no debe usarse en otras estaciones, rutas o buques.
- Drift: si cambian la operación, el buque o la ruta, el error puede aumentar.
- El clima usado es histórico (Open-Meteo), con resolución horaria interpolada; al planificar con pronósticos, el error real sería mayor.
- En el subgrupo de 1 a 6 m/s hay pocas filas (356 en test) y la mejora frente al baseline fue de sólo 5.4 %.
- El GAM es aditivo y no capta interacciones, como que la dirección del viento importe más con viento fuerte.
- Las filas vecinas se parecen, por lo que los intervalos y p-valores son optimistas.

Recomendación: Usar el GAM para estimar el consumo esperado al planificar la carga de combustible en condiciones similares (misma ruta y época), con un margen de ±0.044 kg/s en crucero y ±0.067 kg/s en maniobras (95 %), y para detectar consumos anómalos cuando el consumo real se sale de ese margen. En velocidades de 1 a 6 m/s (maniobras) usarlo con cautela, porque en test mejoró solo 5.4 % frente al baseline. Monitorear el MAE semanal por zona de velocidad (referencia en test: 0.019 kg/s) y la cobertura del intervalo (cercana a 95 %), y reajustar el modelo si el MAE sube más de 20 % de forma sostenida, al cambiar de estación o tras mantenciones del buque.

Referencias

- [1] krohnedigital. FuelCast (conjunto de datos, subconjunto cps_triton). Hugging Face. Licencia CC BY-NC-ND 4.0. https://huggingface.co/datasets/krohnedigital/FuelCast
- [2] Viga, J., Mueck, P., Löser, A. y Weis, T. FuelCast: Benchmarking Tabular and Temporal Models for Ship Fuel Consumption. arXiv:2510.08217, 2025.
- [3] Open-Meteo. Historical Weather API y Marine Weather API. https://open-meteo.com
- [4] R Core Team (2026). R: A Language and Environment for Statistical Computing. Versión 4.6.1. Paquetes: glmnet, mgcv, rpart, ranger, gbm, nnls, dplyr, ggplot2 y arrow.

Anexos

A. Diccionario de variables

Las variables de dirección (viento, ola y corriente) se transforman en el coseno y el seno del ángulo respecto a la proa del buque (Ship_Heading), que representan la componente frontal y la lateral: valores cercanos a 1 en viento_frente y ola_frente indican viento u olas de frente; en corr_frente, corriente a favor (la dirección de la corriente se mide hacia dónde fluye). Los datos meteorológicos vienen cada hora y se interpolaron a 5 minutos (ventana "horaria interpolada"). Las unidades de las variables meteorológicas son las del conjunto FuelCast.

Tabla 3: Diccionario de variables

Variable	Columna original (FuelCast)	Tipo	Unidad	Ventana	Disponibilidad temporal
consumo	Consumer_Total_MomentaryFuel	Respuesta, continua	kg/s	5 min	No existe: es lo que se predice
velocidad	Ship_SpeedOverGround	Continua	m/s	5 min	Velocidad planificada
profundidad	Environment_SeaFloorDepth	Continua	m	5 min	Conocida por la ruta
temp	Weather_Temperature2M	Continua	°C	Horaria interpolada	Histórico (pronóstico en uso real)
viento_vel	Weather_WindSpeed10M	Continua	m/s	Horaria interpolada	Histórico (pronóstico en uso real)
viento_frente	Weather_WindDirection10M y Ship_Heading	Derivada (coseno)	−1 a 1	Horaria interpolada	Histórico (pronóstico en uso real) y rumbo planificado

viento_lado	Weather_WindDirection10M y Ship_Heading	Derivada (seno)	−1 a 1	Horaria interpolada	Histórico (pronóstico en uso real) y rumbo planificado
ola_alt	Weather_WaveHeight	Continua	m	Horaria interpolada	Histórico (pronóstico en uso real)
ola_per	Weather_WavePeriod	Continua	s	Horaria interpolada	Histórico (pronóstico en uso real)
ola_frente	Weather_WaveDirection y Ship_Heading	Derivada (coseno)	−1 a 1	Horaria interpolada	Histórico (pronóstico en uso real) y rumbo planificado
ola_lado	Weather_WaveDirection y Ship_Heading	Derivada (seno)	−1 a 1	Horaria interpolada	Histórico (pronóstico en uso real) y rumbo planificado
corr_vel	Weather_OceanCurrentVelocity	Continua	m/s	Horaria interpolada	Histórico (pronóstico en uso real)
corr_frente	Weather_OceanCurrentDirection y Ship_Heading	Derivada (coseno)	−1 a 1	Horaria interpolada	Histórico (pronóstico en uso real) y rumbo planificado
corr_lado	Weather_OceanCurrentDirection y Ship_Heading	Derivada (seno)	−1 a 1	Horaria interpolada	Histórico (pronóstico en uso real) y rumbo planificado

B. Reproducibilidad y declaración de IA

Cómo ejecutar el script:

1. Subir CPS_Triton.parquet (subconjunto cps_triton de FuelCast, sin modificar) a la carpeta de trabajo; el script lo lee con el paquete arrow.
2. Ejecutar el script completo (partes 0 a 18) desde una sesión limpia de R (Google Colab).
3. Los resultados quedan en la carpeta resultados (tablas de validación y test, incertidumbre, coeficientes, grillas de validación cruzada y configuración de la sesión)
4. El test se evalúa una sola vez, en la Parte 17, con el modelo fijado antes de verlo (modelo_final_manual).

Semillas y versiones: semilla global 123 (set.seed(123)); R 4.6.1; paquetes glmnet 5.2, mgcv 1.9-4, ranger 0.18.0, gbm 2.3.1, rpart 4.1.27, nnls 1.6, dplyr 1.2.1 y ggplot2 4.0.3. El script guarda la sesión en resultados/configuracion_y_sesion.txt. El script usa un solo hilo (BLAS y OpenMP) para que los resultados no cambien entre ejecuciones.

Declaración de uso de IA: se usó Claude (Anthropic) como apoyo para explicar conceptos de estadística, escribir y revisar el código en R y redactar borradores del informe y de la presentación. El equipo ejecutó el script completo, verificó que las cifras del informe y de la presentación coinciden con los archivos de la carpeta resultados y revisó cada decisión metodológica.

C. Resultados completos de validación e hiperparámetros

Tabla 4: Resultados completos de validación (RMSE y MAE en kg/s; subgrupo: velocidad de 1 a 6 m/s).

Modelo	**Familia**	**RMSE general**	**MAE**	**R^2**	**RMSE subgrupo**	**vs baseline**
Baseline (promedio por zona)	—	0.0329	0.0250	0.765	0.0506	n/a
Referencia cúbica	Referencia	0.0309	0.0238	0.793	0.0516	6.2 % menos RMSE
OLS con clima	Lineal	0.0271	0.0203	0.840	0.0421	17.6 % menos RMSE
Ridge	Regularizado	0.0316	0.0239	0.784	0.0532	4.2 % menos RMSE
Lasso	Regularizado	0.0285	0.0213	0.824	0.0450	13.4 % menos RMSE
Elastic-net	Regularizado	0.0287	0.0214	0.822	0.0455	12.9 % menos RMSE
Splines / GAM (modelo final)	Flexible	0.0256	0.0191	0.858	0.0399	22.2 % menos RMSE
Árbol de regresión	Árbol	0.0272	0.0200	0.839	0.0457	17.3 % menos RMSE
Random Forest	Ensemble	0.0252	0.0189	0.863	0.0398	23.6 % menos RMSE
Boosting (gbm)	Ensemble	0.0248	0.0186	0.866	0.0388	24.6 % menos RMSE
Averaging (promedio simple)	Ensemble	0.0248	0.0186	0.867	0.0391	24.7 % menos RMSE
Stacking (pesos OOF)	Ensemble	0.0247	0.0185	0.868	0.0387	25.0 % menos RMSE

Tabla 5: Hiperparámetros elegidos por validación cruzada por bloques y su RMSE de CV

Modelo	**Familia**	**Hiperparámetros elegidos**	**Grilla explorada**	**RMSE CV (kg/s)**

OLS con clima	Lineal	velocidad cúbica + 12 variables	—	0.0266
Lasso	Regularizado	λ = lambda.1se	$\alpha \in \{0; 1; 0.5\}$; λ por CV	0.0277
Splines / GAM	Flexible	k_vel = 80; k_otras = 3	k_vel $\in \{10, 20, 40, 80\}$ × k_otras $\in \{3, 4, 6\}$	0.0252
Árbol de regresión	Árbol	profundidad 6 (44 hojas)	profundidad 3 a 15	0.0257
Random Forest	Ensemble	mtry = 9; nodo mín. = 500	mtry $\in \{6, 9, 12\}$ × nodo $\in \{50, 200, 500, 1000\}$	0.0240
Boosting (gbm)	Ensemble	prof. 6; tasa 0.02; 400 árboles	prof. {2, 4, 6} × tasa {0.02, 0.05, 0.1} × 100–1000 árboles	0.0235
Stacking	Ensemble	pesos 0.65 / 0.22 / 0.07 / 0.06	pesos ≥ 0 sobre predicciones OOF	0.0234

D. Figuras de apoyo

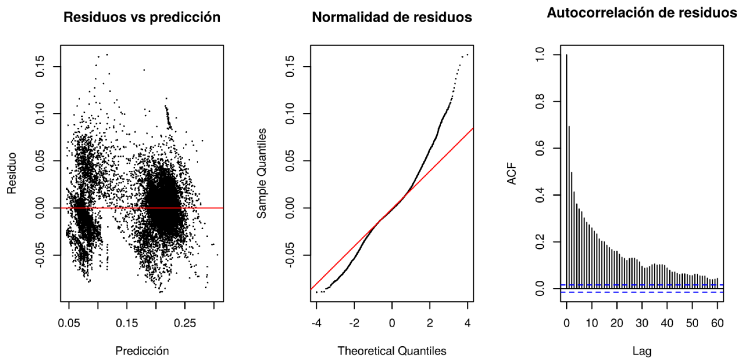


Figura A1. Diagnóstico de residuos del modelo OLS con clima: residuos contra predicción, normalidad de los residuos y autocorrelación de los residuos