INGENIERÍA INDUSTRIAL

UNIVERSIDAD DE SANTIAGO DE CHILE

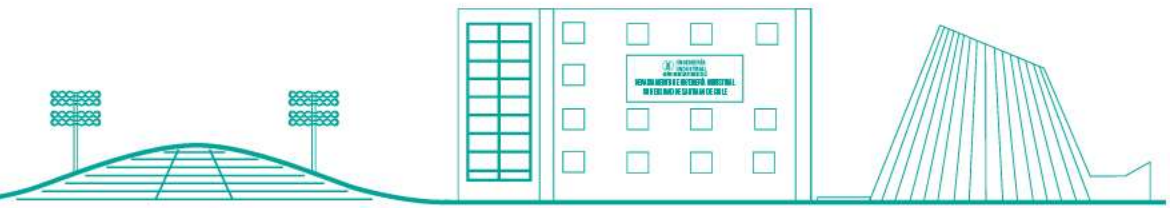
PROYECTO INTEGRADOR REGRESIÓN

Predicción del consumo de combustible del CPS Tritón

- Germán Troncoso
- Hernán Silva
- Isidora Rioseco
- Sylvia Montanares
- Vladimir Painiqueo

Estadística Aplicada · Ingeniería Industrial · USACH

10 min de exposición | 10 min de preguntas



1. Predecir el consumo para planificar el combustible

INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

Estimamos el consumo de cada intervalo de 5 min a partir de la velocidad y el clima de ese mismo intervalo

Problema y usuario

- **Contexto:** el combustible es el mayor costo variable y la fuente de emisiones del buque.
- **Usuario:** operador y planificador de flota del CPS Tritón.
- **Decisión:** cuánto combustible cargar para un viaje, dada la velocidad planificada y el pronóstico del clima.
- **Unidad y población:** intervalo de 5 min de operación de este buque.

Respuesta y costo

- **Respuesta:** consumo total instantáneo (kg/s), continua.
- **Instante:** mismo intervalo; es regresión, no pronóstico de series de tiempo.
- **Subestimar:** reservas insuficientes, riesgo operacional (el error más caro).
- **Sobreestimar:** carga de más: peso y costo extra.
- **Restricción:** solo variables disponibles al predecir (sin sensores de motores).

Condiciones del instante
velocidad, viento, olas, corriente

→

Modelo de regresión
elegido por validación

→

Consumo esperado
kg/s ± intervalo

→

Decisión
cuánto combustible cargar

2. Un dataset con lo que se sabe al navegar

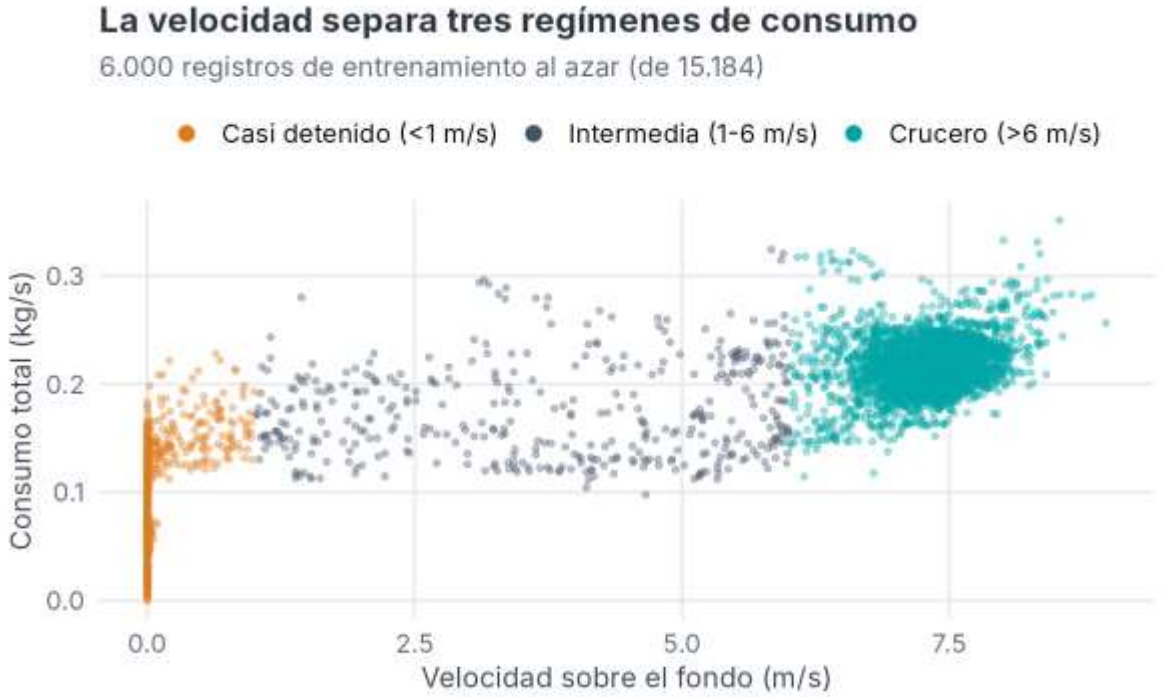
25.351 registros de 5 minutos (~88 días) de un buque, con clima de Open-Meteo

Fuente

- **FuelCast** (Hugging Face), subconjunto cps_triton · licencia CC BY-NC-ND 4.0 · Viga et al., 2025.
- **Tamaño:** 25.351 × 62; quedan 25.308 filas completas.
- **Población:** un buque en una ruta fija, con paradas.

Pertinencia

- **13 predictoras:** velocidad (m/s), viento, olas, corriente, temperatura y profundidad.
- **Direcciones:** seno y coseno del ángulo respecto al rumbo (frente / lado).
- **Descartadas:** columnas Consumer_* y Propeller_*: son parte del propio consumo (fuga).
- **Alternativa descartada:** demanda eléctrica de Alemania (variables posteriores al instante de decidir y huecos en los datos).



3. El viento y la temperatura son los efectos clave

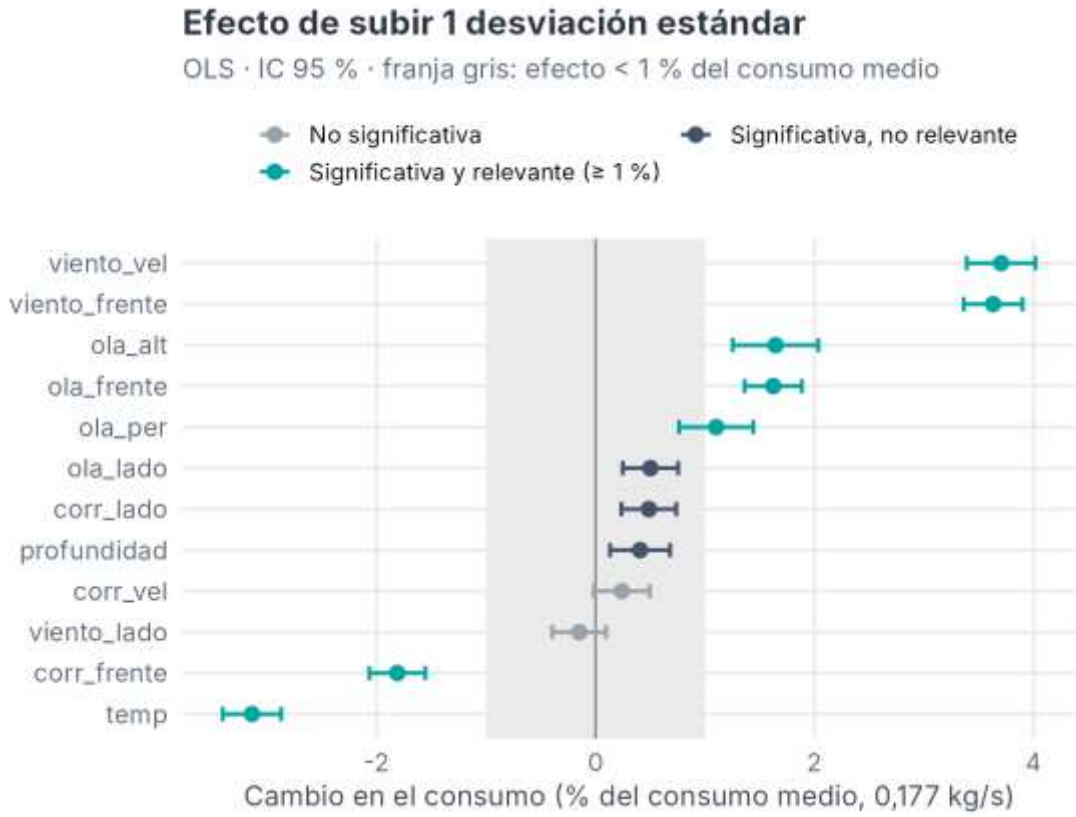
Viento de frente: +3,6 % del consumo medio por desviación estándar (IC 95 %: 3,4 a 3,9 %)

Calidad

- **Faltantes:** 43 filas (0,2 %) en 5 cortes de sensores/clima; se eliminan.
- **Sesgo de selección:** un buque y ~88 días; no extrapolar a otras estaciones.
- **Outliers:** 60 consumos atípicos (IQR); se mantienen: son operación real.

Relación estimada (OLS)

- **Significativo ≠ relevante:** profundidad o corr_lado tienen $p < 0,05$ pero efecto < 1 %.
- **Supuestos:** residuos autocorrelacionados ($r = 0,69$) y de colas pesadas: los IC son optimistas.



4. Partición temporal con el test intacto

INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

Registros vecinos son casi iguales; mezclar al azar inflaría el desempeño

Entrenamiento · 15.184 registros (60 %)	Validación · 5.002	Test · 5.002

tiempo → huecos de 60 registros (5 h) descartados entre conjuntos

Partición

- **Orden de tiempo:** 60/20/20 con hueco de 5 h, donde la autocorrelación se apaga.
- **Test intacto:** se usó una sola vez, con el modelo ya congelado.

CV y preparación

- **Mismos folds:** 5 bloques de tiempo en entrenamiento, con hueco; semilla 123.
- **Sin fuga:** seno/coseno fila a fila; escalas y pesos del stacking solo con entrenamiento.



5. Cinco familias con la misma validación cruzada

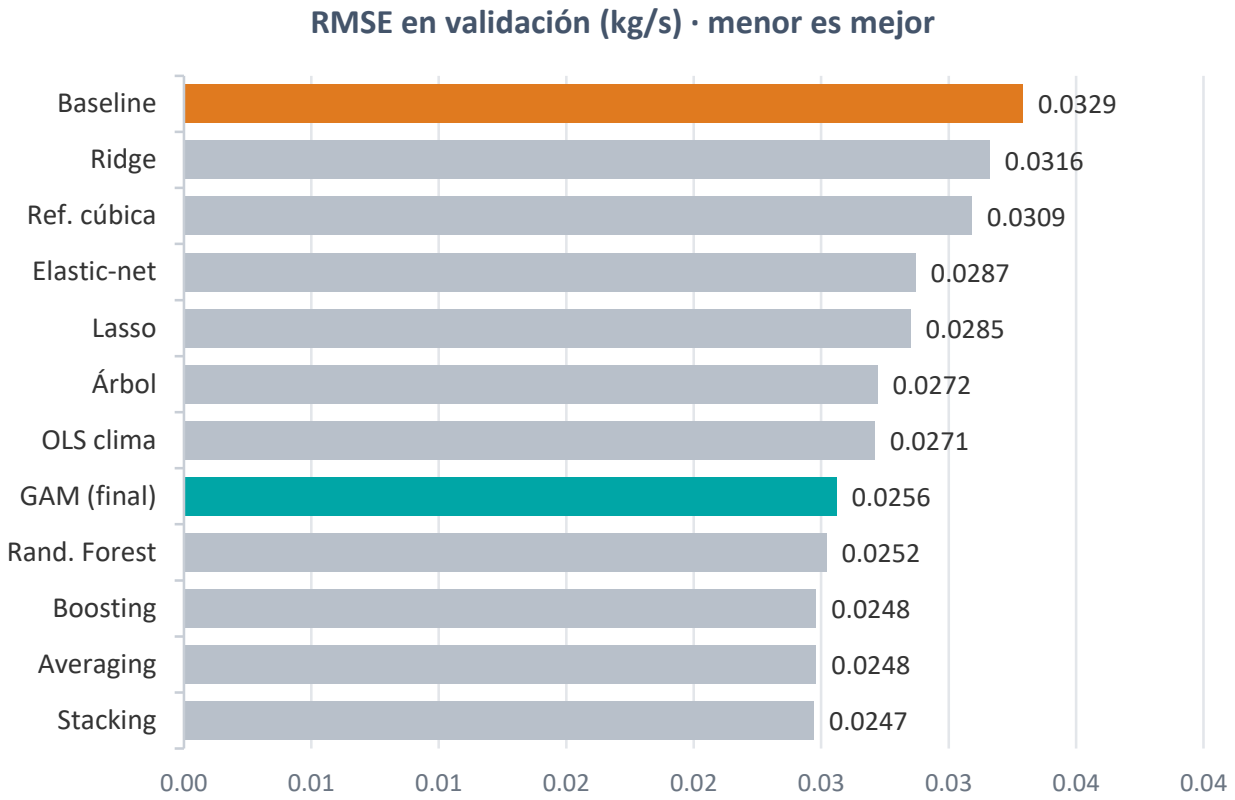
Cada familia agrega flexibilidad; los hiperparámetros se eligieron por RMSE en CV por bloques

Familia	Modelo	Qué aporta	Hiperparámetros elegidos	RMSE CV (kg/s)
Lineal	OLS con clima	Base interpretable; IC y p-valores	velocidad cúbica + 12 variables	0,0266
Regularizada	Ridge / Lasso / Elastic-net	Controla sobreajuste	α = 0 / 1 / 0,5 · λ = lambda.1se	0,0277 (Lasso)
Flexible	**Splines / GAM**	**Curvas no lineales por variable**	**k velocidad = 80 · k resto = 3**	**0,0252**
Árbol	Árbol de regresión	Interacciones y cortes simples	profundidad 6 (44 hojas)	0,0257
Ensemble	Random Forest	Promedia árboles: baja varianza	300 árboles · mtry 9 · nodo ≥ 500	0,0240
Ensemble	Boosting (gbm)	Corrige errores en secuencia	prof. 6 · tasa 0,02 · 400 árboles	0,0235
Ensemble	Stacking	Combina OLS, GAM, RF y boosting	pesos OOF: 0,65 boosting · 0,22 RF	0,0234

Diagnóstico OLS: residuos con curvatura y varianza no constante → motiva el GAM. La regularización casi no ayuda: 15 variables, 15.184 filas y VIF máx. 2,8.

6. El GAM empata con el mejor y es más simple

El GAM, el Boosting, el Averaging y el Stacking empatan: reducen el RMSE entre 22 y 25 % frente al baseline



–22 % RMSE

GAM vs baseline en validación: RMSE 0,0256 vs 0,0329 · MAE 0,0191 vs 0,0250 · R^2 0,86 vs 0,77

0,0045 – 0,0075

IC 95 % de la mejora del MAE (kg/s), bootstrap por bloques: no incluye 0

5 de 5 tramos

de validación en que el GAM le gana al baseline (MAE)

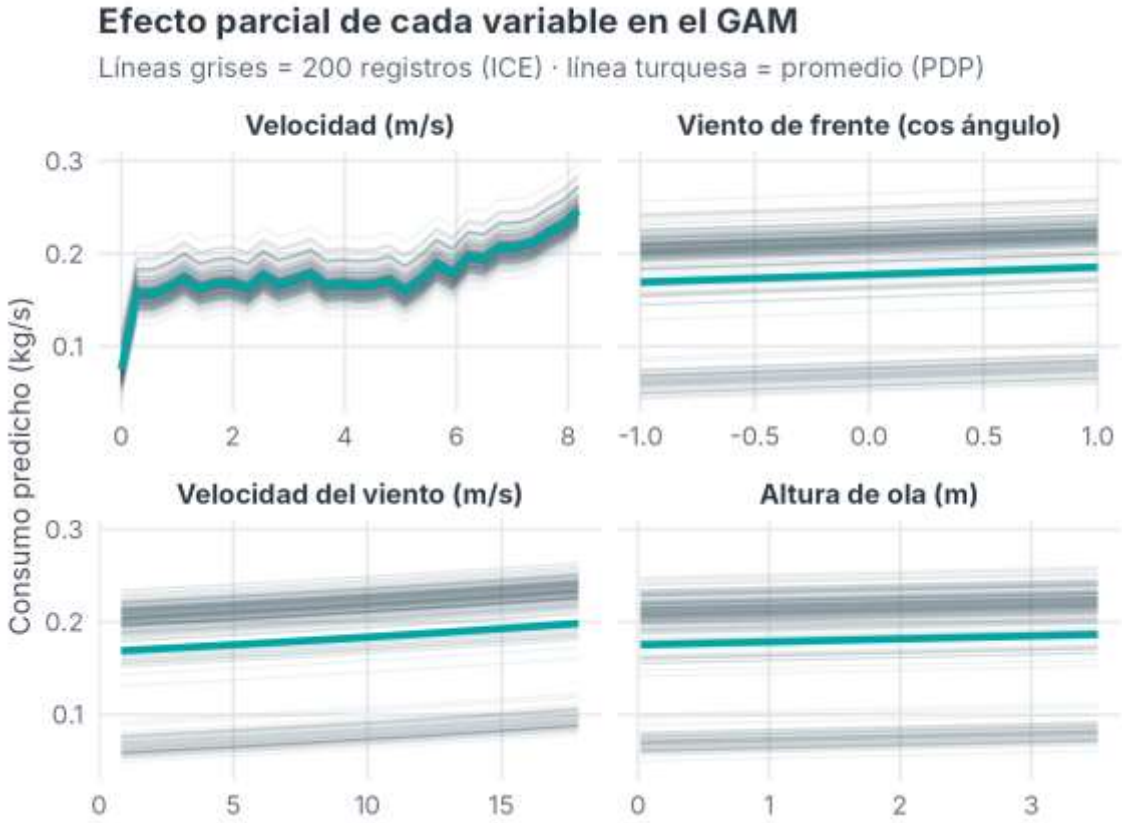
Regla: entre los modelos que no son peores que el mejor (IC del error extra incluye 0), se elige el más simple.

7. La velocidad domina; el clima ajusta poco

Patrones predictivos, no causales: muestran qué usa el modelo, no qué causa el consumo



- **Coeficientes:** viento y olas de frente → más consumo; temperatura → menos.
- **Cautela causal:** datos observacionales; puede haber variables omitidas.



8. En test, el GAM baja el error 18,6 %

INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

Una sola evaluación del sistema congelado: el error se mantiene igual que en validación

Sistema final

- **GAM:** s(velocidad, k = 80) + s(clima, k = 3) + direcciones lineales.
- **Congelado:** ajustado solo con entrenamiento; mismas transformaciones.

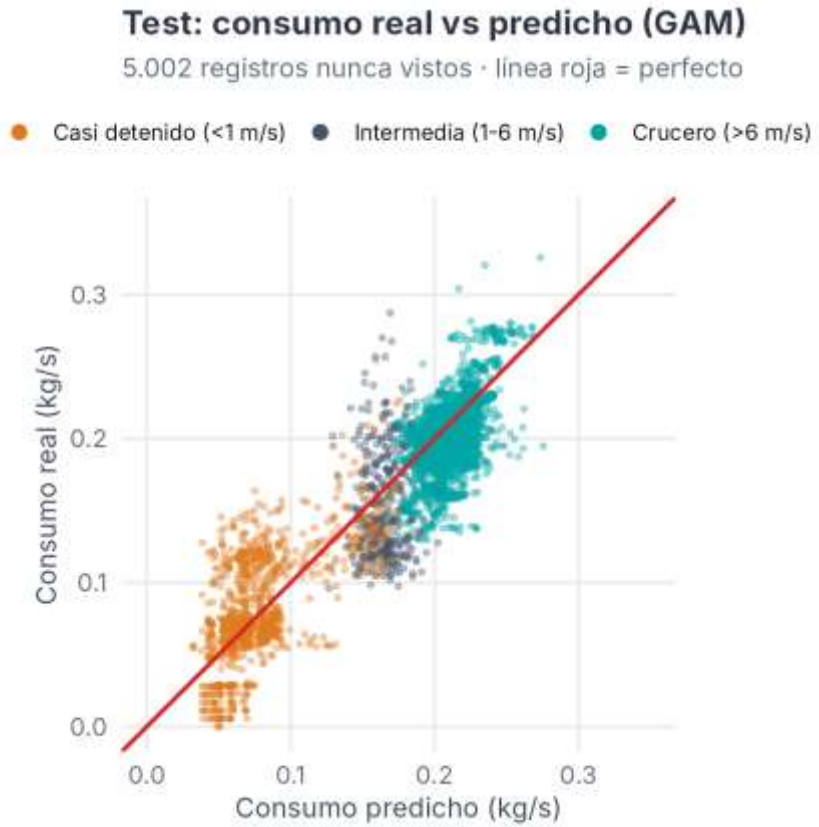
	RMSE (kg/s)	MAE (kg/s)	R^2
Baseline · validación	0,0329	0,0250	0,77
GAM · validación	0,0256	0,0191	0,86
Baseline · test	0,0312	0,0245	0,71
GAM · test	**0,0254**	**0,0194**	**0,81**

0,0037–0,0066

IC 95 % mejora MAE en test (kg/s)

95,2 %

cobertura del intervalo de predicción al 95 %



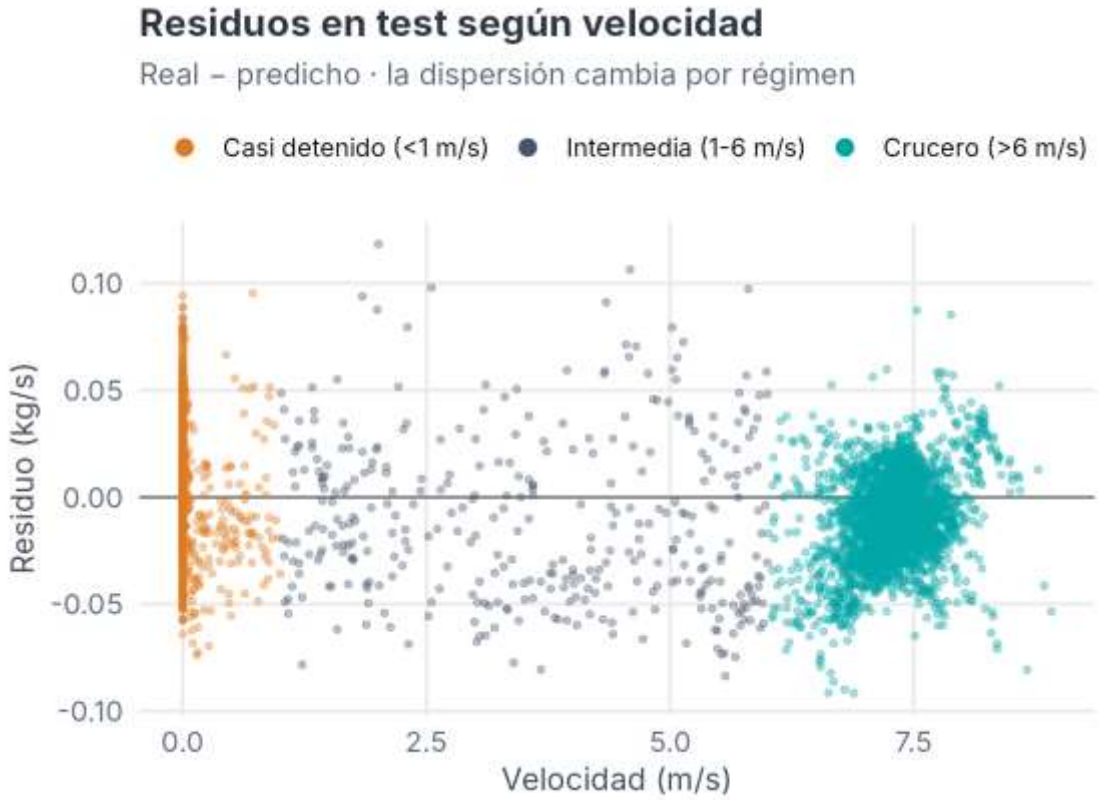
9. El modelo falla más en maniobras (1 a 6 m/s)

Con el barco en maniobra la mejora sobre el baseline cae a 5 %, con solo 356 registros de test

Zona (test)	Registros	Baseline	GAM	Mejora
Casi detenido (< 1 m/s)	1.176	0,0385	0,0296	23 %
Intermedia (1 a 6 m/s)	**356**	**0,0427**	**0,0404**	**5 %**
Crucero (> 6 m/s)	3.470	0,0268	0,0216	19 %

RMSE en kg/s · denominadores = registros de test por zona

- **Heterocedasticidad:** la dispersión del error cambia por régimen.
- **Curvatura:** en maniobra hay pocos datos y la curva del GAM ondula (edf 55).
- **Influyentes:** registros detenidos con consumo ≈ 0 (motores apagados) que el modelo predice ≈ 0,05 kg/s.



10. Usar el GAM, con cautela en maniobras

INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

Estimar el consumo esperado para planificar combustible y detectar consumos anómalos

Recomendación

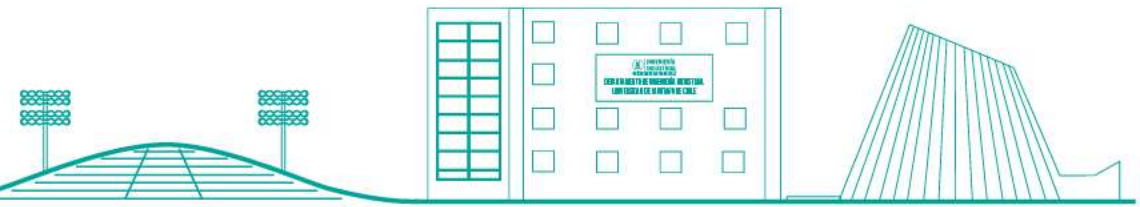
- **Qué y quién:** el planificador usa el GAM para estimar el consumo esperado por tramo y comparar con el real.
- **Margen:** ± 0,044 kg/s en crucero y ± 0,067 kg/s en maniobra (95 %).
- **Población:** solo el CPS Tritón y el rango de clima observado (~88 días).
- **Límite:** no usarlo para decidir causas ni para otros buques.

Monitoreo

1. **Indicadores**
   MAE semanal vs 0,019 kg/s y cobertura del intervalo cercana a 95 %.

2. **Drift**
   cambios en la distribución de velocidad, temperatura y tiempo en maniobra.

3. **Recalibrar**
   si el MAE sube > 20 % por 2 semanas, al cambiar de estación o tras mantenimiento del casco.



PREGUNTAS Y DEFENSA TÉCNICA

INGENIERÍA INDUSTRIAL

UNIVERSIDAD DE SANTIAGO DE CHILE

10 minutos | Todos los integrantes deben poder defender datos, código y decisiones